

Danh Sách 30 Đề Tài Mini-Project Tiểu Luận Cuối Khóa
Học phần: Dữ Liệu Lớn & Trí Tuệ Nhân Tạo Trong Kinh Doanh (Big Data Analytics & AI)

Bộ Môn Phân Tích Dữ Liệu Kinh Tế

2026-09-28

Mục Lục

1	Hướng Dẫn Chung Về Tiểu Luận Cuối Khóa	3
1.1	Định hướng học phần dành cho Khối ngành Kinh tế	3
1.2	Quy định thực hiện và sản phẩm bàn giao	3
2	Hướng Dẫn Triển Khai Theo Chuẩn Big Data Analytics Pipeline Trên Databricks	4
2.1	Kiến Trúc Tổng Thể Luồng Dữ Liệu Lakehouse (Medallion Architecture)	4
2.2	Quy Trình 5 Bước Thực Hiện Dự Án	4
2.2.1	Bước 1: Nạp và Lưu trữ dữ liệu lên Databricks (Ingestion & DBFS Storage)	4
2.2.2	Bước 2: Làm sạch và Chuẩn hóa Dữ liệu (Silver Layer)	5
2.2.3	Bước 3: Phân tích Khám phá & Tính toán Chỉ số Kinh doanh (Spark SQL Analytics)	5
2.2.4	Bước 4: Xây dựng Machine Learning Pipeline Phân Tán với Spark MLlib (Chương 7)	5
2.2.5	Bước 5: Phân tích Ý nghĩa Nghiệp vụ & Đề xuất Chiến lược Kinh doanh	5
3	Bảng Đối Chiếu Quy Chuẩn Thực Hiện Tiểu Luận	6
4	Danh Sách 30 Đề Tài Mini-Project	7
4.1	Lĩnh Vực 1: Thương Mại Điện Tử & Bán Lẻ Hiện Đại (E-Commerce & Retail)	7
4.1.1	Đề tài 1: Dự Báo Khả Năng Hủy Đơn Hàng (Order Cancellation Prediction) Trên Sàn TMĐT	7
4.1.2	Đề tài 2: Xây Dựng Hệ Thống Gợi Ý Sản Phẩm Cá Nhân Hóa (Collaborative Filtering Recommender)	7
4.1.3	Đề tài 3: Phân Khúc Khách Hàng Đa Chiều Bằng Mô Hình RFM Kết Hợp Spark K-Means	7
4.1.4	Đề tài 4: Dự Báo Nhu Cầu Bán Hàng Và Tối Ưu Tồn Kho Theo Chuỗi Thời Gian (Demand Forecasting)	8
4.1.5	Đề tài 5: Phát Hiện Và Lọc Tự Động Đánh Giá Giả Mạo (Fake Review & Spam Detection)	8
4.2	Lĩnh Vực 2: Tài Chính, Ngân Hàng & FinTech (Finance & Banking)	8
4.2.1	Đề tài 6: Hệ Thống Phát Hiện Gian Lận Giao Dịch Thẻ Tín Dụng (Credit Card Fraud Detection)	8
4.2.2	Đề tài 7: Mô Hình Chấm Điểm Tín Dụng Và Thấm Định Rủi Ro Vỡ Nợ (Loan Default & Credit Scoring)	9
4.2.3	Đề tài 8: Dự Báo Xu Hướng Biến Động Giá Cổ Phiếu Và Tín Hiệu Giao Dịch (Stock Trend Prediction)	9
4.2.4	Đề tài 9: Phân Loại Tự Động Danh Mục Chi Tiêu Từ Nội Dung Chuyển Khoản (Transaction Categorization)	9
4.2.5	Đề tài 10: Dự Báo Khách Hàng Tiềm Năng Mua Bảo Hiểm Nhân Thọ (Insurance Cross-Sell Prediction)	9
4.3	Lĩnh Vực 3: Marketing, CSKH & Truyền Thông (Marketing & Customer Experience)	10
4.3.1	Đề tài 11: Dự Báo Tỷ Lệ Khách Hàng Rời Bỏ Dịch Vụ Viễn Thông / OTT (Customer Churn Prediction)	10
4.3.2	Đề tài 12: Dự Báo Giá Trị Vòng Đời Khách Hàng (Customer Lifetime Value - CLV Prediction)	10
4.3.3	Đề tài 13: Dự Báo Tỷ Lệ Nhấp Chuột Vào Quảng Cáo Trực Tuyến (Click-Through Rate - CTR Prediction)	10
4.3.4	Đề tài 14: Phân Tích Sắc Thái Bình Luận Mạng Xã Hội Về Thương Hiệu (Social Media Sentiment Analysis)	10

4.3.5	Đề tài 15: Tối Ưu Hóa Phân Bỏ Ngân Sách Marketing Đa Kênh (Multi-Channel Attribution Modeling)	11
4.4	Lĩnh Vực 4: Logistics, Chuỗi Cung Ứng & Vận Tải (Supply Chain & Transportation)	11
4.4.1	Đề tài 16: Dự Báo Thời Gian Giao Hàng (Estimated Time of Arrival - ETA Prediction)	11
4.4.2	Đề tài 17: Dự Báo Biến Động Giá Cước Vận Tải Hàng Hóa Đường Biển (Freight Rate Forecasting)	11
4.4.3	Đề tài 18: Tối Ưu Hóa Tuyến Đường Và Phân Cụm Điểm Giao Hàng (Delivery Route Clustering)	11
4.4.4	Đề tài 19: Dự Báo Hư Hỏng Thiết Bị Và Bảo Trì Dự Đoán (Predictive Maintenance in Supply Chain)	12
4.4.5	Đề tài 20: Đánh Giá Rủi Ro Thất Lạc & Hư Hỏng Kệ Hàng (Package Damage Risk Assessment)	12
4.5	Lĩnh Vực 5: Du Lịch, Khách Sạn & Dịch Vụ Ẩm Thực (Hospitality & Tourism)	12
4.5.1	Đề tài 21: Mô Hình Định Giá Phòng Khách Sạn Linh Hoạt (Dynamic Pricing Engine)	12
4.5.2	Đề tài 22: Dự Báo Khả Năng Hủy Phòng Khách Sạn (Hotel Booking Cancellation Prediction)	12
4.5.3	Đề tài 23: Hệ Thống Gợi Ý Lịch Trình Và Điểm Đến Du Lịch Cá Nhân Hóa (Travel Destination Recommender)	13
4.5.4	Đề tài 24: Dự Báo Nhu Cầu Đặt Món Trên Nền Tảng Food Delivery (Food Demand Forecasting)	13
4.5.5	Đề tài 25: Phân Khúc Trải Nghiệm Du Khách Dựa Trên Đánh Giá Dịch Vụ (Tourist Segmentation by Reviews)	13
4.6	Lĩnh Vực 6: Y Tế, Nhân Sự & Quản Trị Vận Hành (Healthcare & Operations)	14
4.6.1	Đề tài 26: Dự Báo Chi Phí Bảo Hiểm Y Tế Cá Nhân (Health Insurance Cost Prediction)	14
4.6.2	Đề tài 27: Dự Báo Nhân Viên Nghỉ Việc (HR Employee Attrition Prediction)	14
4.6.3	Đề tài 28: Dự Báo Khả Năng Tái Nhập Viện Của Bệnh Nhân (Hospital Readmission Prediction)	14
4.6.4	Đề tài 29: Dự Báo Mức Tiêu Thụ Điện Năng Cho Nhà Máy Sản Xuất (Industrial Energy Consumption Forecasting)	14
4.6.5	Đề tài 30: Đánh Giá Và Phân Loại Rủi Ro An Toàn Lao Động (Workplace Safety Incident Risk Assessment)	15
5	Tiêu Chí Đánh Giá Tiểu Luận (Rubric)	16

Chương 1

Hướng Dẫn Chung Về Tiểu Luận Cuối Khóa

1.1 Định hướng học phần dành cho Khối ngành Kinh tế

Học phần **Dữ liệu lớn & Trí tuệ nhân tạo trong Kinh doanh** được thiết kế theo định hướng **Ứng dụng nghiệp vụ (Business-Driven & AI-First)**. Sinh viên không đặt nặng việc cài đặt hạ tầng kỹ thuật phức tạp (không yêu cầu cài đặt Docker, cấu hình cụm máy chủ hay quản trị hệ thống), mà tập trung vào:

1. **Tư duy dữ liệu lớn (Big Data Mindset):** Hiểu và khai thác giá trị từ dữ liệu quy mô lớn thông qua mô hình 5Vs (Volume, Velocity, Variety, Veracity, Value).
2. **Nền tảng hợp nhất Databricks Lakehouse:** Sử dụng **Databricks (Databricks Community Edition)** làm môi trường thực thi duy nhất để lưu trữ dữ liệu (**Databricks File System - DBFS & Delta Lake**), truy vấn phân tán (**Spark SQL / PySpark DataFrame**) và mô hình hóa AI (**Spark MLlib**).
3. **Giải quyết bài toán kinh doanh:** Chuyển đổi dữ liệu thành các thông tin chi tiết (Business Insights) nhằm tối ưu hóa chi phí, tăng trưởng doanh thu, phát hiện gian lận và nâng cao trải nghiệm khách hàng.

1.2 Quy định thực hiện và sản phẩm bàn giao

- **Hình thức:** Làm việc theo nhóm (3 - 5 sinh viên/nhóm) hoặc cá nhân.
 - **Môi trường thực hành:** Nền tảng đám mây **Databricks** (sử dụng tài khoản Databricks Community miễn phí).
 - **Sản phẩm bàn giao:**
 1. **Báo cáo tiểu luận hoàn chỉnh (PDF):** Trình bày bài toán kinh doanh, phân tích dữ liệu, giải thích mô hình và khuyến nghị quản trị.
 2. **File Databricks Notebook (.ipynb hoặc .dbc):** Chứa toàn bộ mã nguồn PySpark, Spark SQL, Spark MLlib và biểu đồ trực quan hóa.
 3. **Slide trình bày (PDF/PPTX):** Tóm tắt kết quả nghiên cứu phục vụ bảo vệ đề tài.
-

Chương 2

Hướng Dẫn Triển Khai Theo Chuẩn Big Data Analytics Pipeline Trên Databricks

Để bài tiểu luận đạt chuẩn môn học Dữ liệu lớn và khai thác tối đa sức mạnh của nền tảng **Databricks**, sinh viên thực hiện dự án theo quy trình 5 bước tinh gọn sau:

2.1 Kiến Trúc Tổng Thể Luồng Dữ Liệu Lakehouse (Medallion Architecture)

[Nguồn Dữ Liệu Nghiệp Vụ (CSV / JSON / Web Data)]

(Bước 1: Ingestion & Storage)

[Databricks DBFS / Delta Lake: Bronze Table (Dữ liệu thô ban đầu)]

(Bước 2 & 3: Distributed Cleaning & Analytics)

[PySpark DataFrame & Spark SQL: Silver Table (Dữ liệu chuẩn hóa & KPIs)]

(Bước 4: Distributed AI / Spark MLlib)

[Spark MLlib Pipeline: Gold Table (Kết quả dự báo, phân khúc & gợi ý)]

(Bước 5: Business Insights & Decision Making)

[Databricks Dashboard Trực Quan & Quyết Định Quản Trị Kinh Doanh]

2.2 Quy Trình 5 Bước Thực Hiện Dự Án

2.2.1 Bước 1: Nạp và Lưu trữ dữ liệu lên Databricks (Ingestion & DBFS Storage)

- **Thao tác nạp dữ liệu:** Sinh viên sử dụng giao diện trực quan của Databricks (*Catalog* → *Create Table* → *Upload Files*) hoặc sử dụng lệnh PySpark để nạp dữ liệu trực tiếp vào hệ thống tệp **DBFS** (Databricks File System) tại đường dẫn `dbfs:/FileStore/tables/`.
- **Tạo bảng Bronze (Delta Lake):** Đọc dữ liệu từ DBFS và lưu trữ dưới dạng bảng **Delta Table** để tận dụng khả năng truy vấn tốc độ cao và tính toàn vẹn dữ liệu (ACID transactions):

```
# Ví dụ nạp dữ liệu thô vào bảng Delta Bronze
df_raw = spark.read.format("csv") \
    .option("header", "true") \
    .option("inferSchema", "true") \
```

```
.load("dbfs:/FileStore/tables/dataset.csv")

df_raw.write.format("delta").mode("overwrite").saveAsTable("bronze_data")
```

2.2.2 Bước 2: Làm sạch và Chuẩn hóa Dữ liệu (Silver Layer)

- Sử dụng **PySpark DataFrame** để xử lý các vấn đề chất lượng dữ liệu:
 - Xử lý giá trị bị thiếu (Missing values): `fillna()`, `dropna()`.
 - Xóa bỏ các dòng trùng lặp và chuyển đổi đúng kiểu dữ liệu (Timestamp, Double, Integer).
 - Lọc các giá trị ngoại lai (Outliers) phi thực tế trong kinh doanh.
- Lưu dữ liệu đã làm sạch vào bảng **Silver Table**:

```
df_silver.write.format("delta").mode("overwrite").saveAsTable("silver_data")
```

2.2.3 Bước 3: Phân tích Khám phá & Tính toán Chỉ số Kinh doanh (Spark SQL Analytics)

- Sử dụng kết hợp **Spark SQL** (%sql) và **PySpark** để tính toán các chỉ số kinh doanh cốt lõi (KPIs):
 - Thống kê mô tả (Doanh thu theo vùng, tỷ lệ hoàn tất đơn, thời gian gắn bó của khách hàng).
 - Ứng dụng **Window Functions** để tính trung bình trượt 7 ngày/30 ngày, xếp hạng khách hàng theo giá trị chi tiêu.
- Sử dụng tính năng **Databricks Built-in Charts** (Plot Options) trên Notebook để trực quan hóa biểu đồ trực tiếp mà không cần code phức tạp.

2.2.4 Bước 4: Xây dựng Machine Learning Pipeline Phân Tán với Spark MLlib (Chương 7)

Sinh viên tự động hóa chu trình huấn luyện mô hình bằng `pyspark.ml.Pipeline`:

1. Chuẩn bị biến đặc trưng (Feature Engineering):

- Chuyển đổi nhãn chuỗi dạng danh mục: `StringIndexer`.
- Mã hóa One-Hot: `OneHotEncoder`.
- Gom cụm tất cả các biến đặc trưng thành một cột Vector duy nhất: `VectorAssembler(inputCols=[...], outputCol="features")`.
- Chuẩn hóa thang đo độ lệch chuẩn: `StandardScaler(inputCol="features", outputCol="scaledFeatures")`.

2. Đóng gói Pipeline & Huấn luyện:

```
from pyspark.ml import Pipeline
pipeline = Pipeline(stages=[indexer, encoder, assembler, scaler, model])
pipeline_model = pipeline.fit(train_data)
```

3. Đánh giá mô hình:

- Sử dụng các Evaluator chuẩn của Spark MLlib: `BinaryClassificationEvaluator` (ROC-AUC), `MulticlassClassificationEvaluator` (F1-score, Precision, Recall), `RegressionEvaluator` (RMSE, MAE, R²), `ClusteringEvaluator` (Silhouette Score).

4. Lưu trữ kết quả (Gold Layer):

- Lưu bảng dự đoán vào **Gold Table** để phục vụ việc phân tích kinh doanh.

2.2.5 Bước 5: Phân tích Ý nghĩa Nghiệp vụ & Đề xuất Chiến lược Kinh doanh

- Phân tích các yếu tố ảnh hưởng lớn nhất đến kết quả dự báo (`featureImportances`).
- Đánh giá tác động tài chính: Mô hình giúp tiết kiệm bao nhiêu chi phí nợ xấu, giảm bao nhiêu % tỷ lệ khách hàng rời bỏ, hoặc tăng bao nhiêu doanh thu bán chéo.
- Đề xuất các giải pháp quản trị cụ thể cho ban giám đốc doanh nghiệp.

Chương 3

Bảng Đối Chiếu Quy Chuẩn Thực Hiện Tiểu Luận

Tiêu chí	Cách làm chưa đạt chuẩn môn học	Cách làm chuẩn Databricks Big Data
Môi trường thực thi	Chạy Jupyter Notebook rời rạc trên máy tính cá nhân	Thực thi trên nền tảng Databricks Community Cloud
Nơi lưu trữ dữ liệu	Đọc file .csv cục bộ từ ổ cứng C/D	Lưu trữ tập trung trên Databricks DBFS & Delta Lake
Công cụ xử lý bảng	Dùng thư viện pandas (chỉ xử lý dữ liệu nhỏ trong RAM máy)	Dùng PySpark DataFrame (spark.read) và Spark SQL
Thuật toán Machine Learning	Dùng thư viện đơn luồng scikit-learn	Dùng Spark MLlib (pyspark.ml) Pipeline phân tán
Trực quan hóa kết quả	Chụp ảnh màn hình thủ công	Sử dụng Databricks Dashboards / Built-in Visualizations
Tư duy kết quả	Chỉ báo cáo độ chính xác kỹ thuật (Accuracy %)	Phân tích tác động tài chính, chỉ số ROI và quyết định quản trị

Chương 4

Danh Sách 30 Đề Tài Mini-Project

4.1 Lĩnh Vực 1: Thương Mại Điện Tử & Bán Lẻ Hiện Đại (E-Commerce & Retail)

4.1.1 Đề tài 1: Dự Báo Khả Năng Hủy Đơn Hàng (Order Cancellation Prediction) Trên Sàn TMĐT

- **Bài toán kinh doanh:** Giúp bộ phận vận hành phát hiện sớm đơn hàng có xác suất bị hủy cao để liên hệ xác nhận, giảm chi phí đóng gói vô ích và tối ưu tỷ lệ hoàn tất đơn.
- **Pipeline trên Databricks:**
 - *Lưu trữ (DBFS/Delta):* Nạp dữ liệu log đặt hàng vào DBFS, tạo bảng `bronze_orders` dạng Delta Lake.
 - *Xử lý (PySpark & SQL):* Làm sạch dữ liệu, trích xuất biến: hình thức thanh toán, thời gian xem hàng, lịch sử mua sắm của User → bảng `silver_orders`.
 - *AI/MLlib (Spark ML):* Xây dựng Pipeline phân loại nhị phân (**Logistic Regression / Random Forest**) dự đoán nhãn `is_canceled` → bảng `gold_cancellation_predictions`.
 - *Giá trị quản trị:* Đề xuất chính sách đặt cọc linh hoạt cho các đơn hàng có điểm rủi ro hủy cao.
- **Dataset đề xuất:** *Brazilian E-Commerce Public Dataset by Olist (Kaggle).*

4.1.2 Đề tài 2: Xây Dựng Hệ Thống Gợi Ý Sản Phẩm Cá Nhân Hóa (Collaborative Filtering Recommender)

- **Bài toán kinh doanh:** Tăng giá trị giỏ hàng trung bình (AOV) và tỷ lệ chuyển đổi (Conversion Rate) bằng widget “Gợi ý dành riêng cho bạn”.
- **Pipeline trên Databricks:**
 - *Lưu trữ (DBFS/Delta):* Lưu bảng lịch sử đánh giá sản phẩm (User-Item Ratings) trên DBFS.
 - *Xử lý (PySpark & SQL):* Tạo ma trận tương tác khách hàng - sản phẩm qua Spark SQL.
 - *AI/MLlib (Spark ML):* Huấn luyện mô hình lọc cộng tác **ALS (Alternating Least Squares)**; sinh danh sách Top-10 sản phẩm đề xuất cho từng khách hàng.
 - *Giá trị quản trị:* Xây dựng chiến lược gửi email tự động với các sản phẩm được cá nhân hóa.
- **Dataset đề xuất:** *Amazon Product Reviews Dataset / Instacart Market Basket Analysis.*

4.1.3 Đề tài 3: Phân Khúc Khách Hàng Đa Chiều Bằng Mô Hình RFM Kết Hợp Spark K-Means

- **Bài toán kinh doanh:** Tự động gom nhóm tệp hàng triệu khách hàng thành: *Khách hàng VIP, Khách hàng trung thành, Khách hàng có nguy cơ rời bỏ* để phân bổ ngân sách khuyến mãi chính xác.
- **Pipeline trên Databricks:**
 - *Lưu trữ (DBFS/Delta):* Nạp dữ liệu hóa đơn bán lẻ vào Delta Table `bronze_retail`.
 - *Xử lý (PySpark & SQL):* Dùng Spark SQL tính toán 3 chỉ số RFM: *Recency* (ngày mua gần nhất), *Frequency* (tần suất), *Monetary* (tổng chi tiêu).

- *AI/MLlib (Spark ML)*: Chuẩn hóa đặc trưng bằng **StandardScaler** và gom cụm tự động bằng **K-Means (Spark MLlib)** với phương pháp Elbow.
- *Giá trị quản trị*: Thiết kế chương trình tri ân riêng biệt cho nhóm khách VIP và chương trình kích hoạt lại nhóm khách ngủ đông.
- **Dataset đề xuất**: *Online Retail II Data Set (UCI Machine Learning Repository)*.

4.1.4 Đề tài 4: Dự Báo Nhu Cầu Bán Hàng Và Tối Ưu Tồn Kho Theo Chuỗi Thời Gian (Demand Forecasting)

- **Bài toán kinh doanh**: Dự báo số lượng hàng bán ra từng tuần cho chuỗi siêu thị nhằm giảm thiểu chi phí lưu kho và tránh tình trạng đứt gãy nguồn cung.
- **Pipeline trên Databricks**:
 - *Lưu trữ (DBFS/Delta)*: Nạp lịch sử doanh số bán hàng hàng ngày lên DBFS.
 - *Xử lý (PySpark & SQL)*: Dùng PySpark Window Functions tạo các biến trễ (Lag 7 ngày, Moving Average 14 ngày, biến mùa vụ).
 - *AI/MLlib (Spark ML)*: Xây dựng mô hình hồi quy phân tán **GBRegressor (Gradient Boosted Trees)** dự báo `sales_quantity`.
 - *Giá trị quản trị*: Tối ưu hóa chu kỳ đặt hàng bổ sung cho bộ phận thu mua.
- **Dataset đề xuất**: *Store Item Demand Forecasting Challenge (Kaggle)*.

4.1.5 Đề tài 5: Phát Hiện Và Lọc Tự Động Đánh Giá Giả Mạo (Fake Review & Spam Detection)

- **Bài toán kinh doanh**: Tự động phát hiện các bài đánh giá rác, “seeding” ảo hoặc công kích đối thủ để bảo vệ độ tin cậy của sản phẩm thương mại điện tử.
- **Pipeline trên Databricks**:
 - *Lưu trữ (DBFS/Delta)*: Nạp dữ liệu văn bản đánh giá vào Delta Table.
 - *Xử lý (PySpark & SQL)*: Xử lý NLP phân tán với **Tokenizer**, **StopWordsRemover**, **HashingTF**, **IDF**.
 - *AI/MLlib (Spark ML)*: Huấn luyện mô hình phân loại **Naive Bayes / Logistic Regression** để gắn nhãn đánh giá Thật / Ảo.
 - *Giá trị quản trị*: Tự động ẩn các bài đánh giá vi phạm và gắn cờ tài khoản có hành vi bất thường.
- **Dataset đề xuất**: *Yelp Review Dataset / Amazon Musical Instruments Reviews*.

4.2 Lĩnh Vực 2: Tài Chính, Ngân Hàng & FinTech (Finance & Banking)

4.2.1 Đề tài 6: Hệ Thống Phát Hiện Gian Lận Giao Dịch Thẻ Tín Dụng (Credit Card Fraud Detection)

- **Bài toán kinh doanh**: Cảnh báo tức thì các giao dịch quẹt thẻ bất thường (bị lộ mã CVV, quẹt thẻ ở khoảng cách địa lý vô lý) nhằm bảo vệ tiền gửi của khách hàng.
- **Pipeline trên Databricks**:
 - *Lưu trữ (DBFS/Delta)*: Lưu trữ tập dữ liệu hàng trăm nghìn giao dịch thẻ trên DBFS Delta Lake.
 - *Xử lý (PySpark & SQL)*: Phân tích độ lệch chuẩn của số tiền giao dịch và tần suất quẹt thẻ theo giờ.
 - *AI/MLlib (Spark ML)*: Xử lý mất cân bằng dữ liệu và huấn luyện mô hình phân loại **Random Forest / GBClassifier**; tối ưu hóa theo chỉ số AUC-PR.
 - *Giá trị quản trị*: Thiết lập hệ thống ngưỡng điểm rủi ro (Risk Score) để tự động khóa thẻ tạm thời hoặc yêu cầu xác thực OTP bước 2.
- **Dataset đề xuất**: *Credit Card Fraud Detection Dataset (ULB / Kaggle)*.

4.2.2 Đề tài 7: Mô Hình Chấm Điểm Tín Dụng Và Thẩm Định Rủi Ro Vỡ Nợ (Loan Default & Credit Scoring)

- **Bài toán kinh doanh:** Tự động hóa quy trình phê duyệt hồ sơ vay tiêu dùng tín chấp, kiểm soát tỷ lệ nợ xấu (NPL).
- **Pipeline trên Databricks:**
 - *Lưu trữ (DBFS/Delta):* Lưu trữ thông tin nhân khẩu học, thu nhập, lịch sử trả nợ trên Delta Table.
 - *Xử lý (PySpark & SQL):* Mã hóa các biến danh mục bằng **StringIndexer** và **OneHotEncoder**.
 - *AI/MLlib (Spark ML):* Huấn luyện mô hình **Logistic Regression & Decision Tree** với **CrossValidator** để phân tầng rủi ro người vay.
 - *Giá trị quản trị:* Xác định hạn mức tín dụng và lãi suất vay tương ứng với từng mức độ rủi ro của khách hàng.
- **Dataset đề xuất:** *Home Credit Default Risk / Lending Club Loan Data.*

4.2.3 Đề tài 8: Dự Báo Xu Hướng Biến Động Giá Cổ Phiếu Và Tín Hiệu Giao Dịch (Stock Trend Prediction)

- **Bài toán kinh doanh:** Cung cấp công cụ phân tích kỹ thuật và cảnh báo xu hướng thị trường phục vụ ra quyết định đầu tư chứng khoán.
- **Pipeline trên Databricks:**
 - *Lưu trữ (DBFS/Delta):* Nạp dữ liệu giá lịch sử OHLCV vào DBFS.
 - *Xử lý (PySpark & SQL):* Dùng Spark SQL Window Functions tính các chỉ báo kỹ thuật: MA(20), RSI(14), MACD, Bollinger Bands.
 - *AI/MLlib (Spark ML):* Dự báo giá đóng cửa bằng **Linear Regression / GBTRRegressor** và phân loại tín hiệu Mua/Bán (Buy/Sell).
 - *Giá trị quản trị:* Xây dựng danh mục đầu tư mẫu và mô phỏng tỷ suất sinh lời quá khứ (Backtesting).
- **Dataset đề xuất:** *S&P500 Stock Market Data / Dữ liệu chứng khoán VN30.*

4.2.4 Đề tài 9: Phân Loại Tự Động Danh Mục Chi Tiêu Từ Nội Dung Chuyển Khoản (Transaction Categorization)

- **Bài toán kinh doanh:** Tính năng “Sổ thu chi thông minh” trên ứng dụng ngân hàng số giúp người dùng tự động gom nhóm chi tiêu (Ăn uống, Mua sắm, Hóa đơn, Tiết kiệm).
- **Pipeline trên Databricks:**
 - *Lưu trữ (DBFS/Delta):* Lưu trữ log sao kê tài khoản ngân hàng trên Delta Lake.
 - *Xử lý (PySpark & SQL):* Tiền xử lý chuỗi văn bản, trích xuất từ khóa với **CountVectorizer** trong Spark MLlib.
 - *AI/MLlib (Spark ML):* Huấn luyện mô hình phân loại đa lớp **Multiclass Logistic Regression**.
 - *Giá trị quản trị:* Cung cấp báo cáo tài chính cá nhân tự động giúp tăng mức độ gắn bó (Engagement) của người dùng với ứng dụng ngân hàng.
- **Dataset đề xuất:** *Bank Transaction Categorization Dataset.*

4.2.5 Đề tài 10: Dự Báo Khách Hàng Tiềm Năng Mua Bảo Hiểm Nhân Thọ (Insurance Cross-Sell Prediction)

- **Bài toán kinh doanh:** Giúp ngân hàng/công ty bảo hiểm chọn lọc danh sách khách hàng đang dùng thẻ có xác suất mua bảo hiểm cao nhất để tối ưu chi phí Telesales.
- **Pipeline trên Databricks:**
 - *Lưu trữ (DBFS/Delta):* Nạp hồ sơ khách hàng vào Delta Table **bronze_customers**.
 - *Xử lý (PySpark & SQL):* Tổng hợp độ tuổi, tình trạng hôn nhân, số dư tiết kiệm và lịch sử chi tiêu qua Spark DataFrame.
 - *AI/MLlib (Spark ML):* Xây dựng Pipeline phân loại khách hàng tiềm năng bằng **Decision Tree / Random Forest**.
 - *Giá trị quản trị:* Cắt giảm 40% chi phí gọi điện tiếp thị đại trà, nâng cao tỷ lệ chốt hợp đồng.
- **Dataset đề xuất:** *Health Insurance Cross Sell Prediction (Kaggle).*

4.3 Lĩnh Vực 3: Marketing, CSKH & Truyền Thông (Marketing & Customer Experience)

4.3.1 Đề tài 11: Dự Báo Tỷ Lệ Khách Hàng Rời Bỏ Dịch Vụ Viễn Thông / OTT (Customer Churn Prediction)

- **Bài toán kinh doanh:** Nhận diện sớm khách hàng có ý định hủy gói cước Internet/Truyền hình để chủ động tặng ưu đãi giữ chân kịp thời.
- **Pipeline trên Databricks:**
 - *Lưu trữ (DBFS/Delta):* Lưu trữ thông tin hợp đồng, cước phí hàng tháng, số lần khiếu nại trên Delta Lake.
 - *Xử lý (PySpark & SQL):* Tạo biến tổng hợp thời gian gắn bó (Tenure), hình thức thanh toán và loại hợp đồng.
 - *AI/MLlib (Spark ML):* Huấn luyện **Random Forest Classifier** kết hợp **CrossValidator** để dự đoán nhân Churn.
 - *Giá trị quản trị:* Đề xuất gói khuyến mãi chuyên biệt cho nhóm khách hàng có nguy cơ rời bỏ cao nhất.
- **Dataset đề xuất:** *Telco Customer Churn Dataset (IBM / Kaggle).*

4.3.2 Đề tài 12: Dự Báo Giá Trị Vòng Đời Khách Hàng (Customer Lifetime Value - CLV Prediction)

- **Bài toán kinh doanh:** Ước tính tổng giá trị lợi nhuận một khách hàng mang lại trong tương lai để xác định chi phí thu hút khách hàng (CAC) hợp lý.
- **Pipeline trên Databricks:**
 - *Lưu trữ (DBFS/Delta):* Lưu trữ bảng lịch sử thanh toán dạng Delta Table trên DBFS.
 - *Xử lý (PySpark & SQL):* Dùng Spark SQL tính tần suất mua sắm, giá trị đơn hàng trung bình và chu kỳ mua hàng.
 - *AI/MLlib (Spark ML):* Hồi quy dự báo giá trị chỉ tiêu trong tương lai bằng **Linear Regression / GBTRRegressor**.
 - *Giá trị quản trị:* Tối ưu hóa phân bổ ngân sách chăm sóc khách hàng dựa trên giá trị CLV dự báo.
- **Dataset đề xuất:** *Online Retail / CDNOW Customer Transaction Dataset.*

4.3.3 Đề tài 13: Dự Báo Tỷ Lệ Nhấp Chuột Vào Quảng Cáo Trực Tuyến (Click-Through Rate - CTR Prediction)

- **Bài toán kinh doanh:** Giúp nền tảng AdTech tối ưu hóa việc phân phối banner quảng cáo đúng đối tượng mục tiêu nhằm nâng cao doanh thu quảng cáo.
- **Pipeline trên Databricks:**
 - *Lưu trữ (DBFS/Delta):* Lưu trữ tệp dữ liệu log hiển thị banner quảng cáo trên DBFS.
 - *Xử lý (PySpark & SQL):* Mã hóa các biến thuộc tính người dùng, thiết bị và vị trí hiển thị bằng **StringIndexer**.
 - *AI/MLlib (Spark ML):* Phân loại xác suất Click bằng **Logistic Regression (Spark MLlib)**.
 - *Giá trị quản trị:* Tối ưu hóa thuật toán đấu thầu hiển thị thời gian thực (Real-time Bidding).
- **Dataset đề xuất:** *Criteo Display Advertising Challenge / Avazu CTR Dataset.*

4.3.4 Đề tài 14: Phân Tích Sắc Thái Bình Luận Mạng Xã Hội Về Thương Hiệu (Social Media Sentiment Analysis)

- **Bài toán kinh doanh:** Đo lường sức khỏe thương hiệu (Brand Health) và phát hiện sớm khủng hoảng truyền thông từ thảo luận của cộng đồng mạng.
- **Pipeline trên Databricks:**
 - *Lưu trữ (DBFS/Delta):* Nạp dữ liệu bài đăng/bình luận mạng xã hội vào Delta Table.
 - *Xử lý (PySpark & SQL):* PySpark xử lý văn bản: tách từ, lọc stop words, sinh đặc trưng TF-IDF.
 - *AI/MLlib (Spark ML):* Phân loại cảm xúc 3 lớp (*Tích cực, Tiêu cực, Trung tính*) bằng **Logistic Regression / Naive Bayes**.
 - *Giá trị quản trị:* Xây dựng bảng điều khiển theo dõi cảm xúc thương hiệu theo thời gian thực.
- **Dataset đề xuất:** *Twitter Sentiment140 Dataset / Airline Sentiment on Twitter.*

4.3.5 Đề tài 15: Tối Ưu Hóa Phân Bỏ Ngân Sách Marketing Đa Kênh (Multi-Channel Attribution Modeling)

- **Bài toán kinh doanh:** Đo lường mức độ đóng góp của từng kênh (Google Ads, Facebook Ads, Email, TikTok) vào quyết định mua hàng cuối cùng.
 - **Pipeline trên Databricks:**
 - *Lưu trữ (DBFS/Delta):* Lưu trữ hành trình click chuột (Clickstream Journey) của người dùng trên Delta Lake.
 - *Xử lý (PySpark & SQL):* Dùng PySpark Window Functions lần vết chuỗi điểm chạm (Touchpoints) trước khi mua hàng.
 - *AI/MLlib (Spark ML):* Phân cụm hành trình mua sắm của khách hàng bằng **K-Means**.
 - *Giá trị quản trị:* Tái phân bổ ngân sách quảng cáo từ kênh kém hiệu quả sang kênh có tỷ lệ chuyển đổi cao.
 - **Dataset đề xuất:** *Multi-channel Marketing Attribution Dataset*.
-

4.4 Lĩnh Vực 4: Logistics, Chuỗi Cung Ứng & Vận Tải (Supply Chain & Transportation)

4.4.1 Đề tài 16: Dự Báo Thời Gian Giao Hàng (Estimated Time of Arrival - ETA Prediction)

- **Bài toán kinh doanh:** Cung cấp thời gian nhận hàng chính xác cho người mua trên ứng dụng giao nhận (Grab, ShopeeFood, GHN), nâng cao chỉ số hài lòng (CSAT).
- **Pipeline trên Databricks:**
 - *Lưu trữ (DBFS/Delta):* Lưu trữ lịch sử các chuyến giao hàng trên DBFS.
 - *Xử lý (PySpark & SQL):* Tính toán khoảng cách địa lý, điều kiện thời tiết và mật độ giao thông theo khung giờ bằng Spark DataFrame.
 - *AI/MLlib (Spark ML):* Huấn luyện mô hình hồi quy **GBRegressor** / **Random Forest Regressor** dự đoán số phút giao hàng.
 - *Giá trị quản trị:* Thiết lập cam kết thời gian giao hàng (SLA) chuẩn xác và tối ưu điều phối tài xế.
- **Dataset đề xuất:** *NYC Taxi Trip Duration / Delivery Logistics Dataset*.

4.4.2 Đề tài 17: Dự Báo Biến Động Giá Cước Vận Tải Hàng Hóa Đường Biển (Freight Rate Forecasting)

- **Bài toán kinh doanh:** Giúp doanh nghiệp xuất nhập khẩu chủ động lập kế hoạch ngân sách logistics và đàm phán hợp đồng vận chuyển dài hạn.
- **Pipeline trên Databricks:**
 - *Lưu trữ (DBFS/Delta):* Nạp dữ liệu cước tàu, giá nhiên liệu và chỉ số container vào Delta Table.
 - *Xử lý (PySpark & SQL):* Kết hợp các chỉ báo kinh tế vĩ mô và lịch sử biến động giá cước bằng Spark SQL.
 - *AI/MLlib (Spark ML):* Xây dựng mô hình hồi quy đa biến **Linear Regression** / **GBRegressor**.
 - *Giá trị quản trị:* Giúp doanh nghiệp chủ động lựa chọn thời điểm ký kết hợp đồng cước tàu tối ưu.
- **Dataset đề xuất:** *Global Freight Rate Index / Container Shipping Dataset*.

4.4.3 Đề tài 18: Tối Ưu Hóa Tuyến Đường Và Phân Cụm Điểm Giao Hàng (Delivery Route Clustering)

- **Bài toán kinh doanh:** Gom nhóm các đơn hàng trong cùng một khu vực để giao chung một chuyến xe, tiết kiệm nhiên liệu và nhân công vận chuyển.
- **Pipeline trên Databricks:**
 - *Lưu trữ (DBFS/Delta):* Lưu trữ tọa độ (Latitude, Longitude) danh sách các điểm giao hàng trên DBFS.
 - *Xử lý (PySpark & SQL):* Tính toán ma trận khoảng cách giữa các điểm giao bằng PySpark.
 - *AI/MLlib (Spark ML):* Phân cụm các điểm giao hàng theo vị trí không gian bằng **K-Means (Spark MLlib)**.

- *Giá trị quản trị*: Tối ưu hóa lộ trình xe tải, giảm 20% chi phí xăng dầu vận hành hàng tháng.
- **Dataset đề xuất**: *E-commerce Delivery Location Dataset*.

4.4.4 Đề tài 19: Dự Báo Hư Hỏng Thiết Bị Và Bảo Trì Dự Đoán (Predictive Maintenance in Supply Chain)

- **Bài toán kinh doanh**: Dự báo thời điểm máy móc/xe tải vận tải gặp sự cố để bảo dưỡng định kỳ trước, tránh đứt gãy chuỗi cung ứng.
- **Pipeline trên Databricks**:
 - *Lưu trữ (DBFS/Delta)*: Nạp log cảm biến IoT (nhiệt độ, độ rung, số giờ hoạt động) vào Delta Lake.
 - *Xử lý (PySpark & SQL)*: Tính toán giá trị trung bình trượt và độ lệch chuẩn của các chỉ số cảm biến.
 - *AI/MLlib (Spark ML)*: Phân loại nhị phân **Random Forest Classifier** dự đoán nguy cơ xảy ra sự cố máy móc.
 - *Giá trị quản trị*: Chuyển từ bảo trì bị động sang bảo trì dự đoán, giảm thiểu thời gian dừng hoạt động của nhà máy.
- **Dataset đề xuất**: *AI4I 2020 Predictive Maintenance Dataset (UCI)*.

4.4.5 Đề tài 20: Đánh Giá Rủi Ro Thất Lạc & Hư Hỏng Kiện Hàng (Package Damage Risk Assessment)

- **Bài toán kinh doanh**: Đánh giá rủi ro hư hỏng kiện hàng dựa trên chủng loại hàng, tuyến đường vận chuyển và đối tác vận tải để mua bảo hiểm phù hợp.
- **Pipeline trên Databricks**:
 - *Lưu trữ (DBFS/Delta)*: Nạp dữ liệu lịch sử bồi thường và tình trạng kiện hàng vào DBFS.
 - *Xử lý (PySpark & SQL)*: Tổng hợp biến: loại bao bì, trọng lượng, số điểm trung chuyển qua Spark DataFrame.
 - *AI/MLlib (Spark ML)*: Huấn luyện mô hình phân loại rủi ro bằng **Decision Tree / Logistic Regression**.
 - *Giá trị quản trị*: Thiết lập quy chuẩn đóng gói chuyên biệt cho các nhóm hàng có điểm rủi ro cao.
- **Dataset đề xuất**: *Supply Chain Logistics Shipment Data*.

4.5 Lĩnh Vực 5: Du Lịch, Khách Sạn & Dịch Vụ Ẩm Thực (Hospitality & Tourism)

4.5.1 Đề tài 21: Mô Hình Định Giá Phòng Khách Sạn Linh Hoạt (Dynamic Pricing Engine)

- **Bài toán kinh doanh**: Tự động điều chỉnh giá phòng theo thời gian thực dựa trên tỷ lệ lấp đầy, mùa cao điểm, sự kiện địa phương và giá đối thủ cạnh tranh.
- **Pipeline trên Databricks**:
 - *Lưu trữ (DBFS/Delta)*: Lưu lịch sử đặt phòng và giá đối thủ trên Delta Lake.
 - *Xử lý (PySpark & SQL)*: Dùng Spark SQL tính tỷ lệ lấp đầy lịch sử (Occupancy Rate) và biến mùa vụ.
 - *AI/MLlib (Spark ML)*: Hồi quy dự báo mức giá phòng tối ưu bằng **GBTRRegressor (Spark MLlib)**.
 - *Giá trị quản trị*: Tối đa hóa doanh thu trên mỗi phòng sẵn có (RevPAR) cho khách sạn.
- **Dataset đề xuất**: *Hotel Booking Demand Dataset (Kaggle)*.

4.5.2 Đề tài 22: Dự Báo Khả Năng Hủy Phòng Khách Sạn (Hotel Booking Cancellation Prediction)

- **Bài toán kinh doanh**: Dự báo khách đặt phòng có nguy cơ “No-Show” hoặc hủy phòng phút chót để khách sạn chủ động áp dụng chính sách Overbooking an toàn.
- **Pipeline trên Databricks**:

- *Lưu trữ (DBFS/Delta)*: Nạp dữ liệu lịch sử đặt phòng vào Delta Table.
- *Xử lý (PySpark & SQL)*: Trích xuất biến Lead Time (số ngày đặt trước), số lượng khách và hình thức đặt cọc.
- *AI/MLlib (Spark ML)*: Phân loại nhị phân dự đoán hủy phòng bằng **Random Forest / Logistic Regression**.
- *Giá trị quản trị*: Xác định tỷ lệ phòng cho phép Overbooking tối ưu để không bị trống phòng.
- **Dataset đề xuất**: *Hotel Booking Demand Dataset (Antonio, de Almeida and Nunes, 2019)*.

4.5.3 Đề tài 23: Hệ Thống Gợi Ý Lịch Trình Và Điểm Đến Du Lịch Cá Nhân Hóa (Travel Destination Recommender)

- **Bài toán kinh doanh**: Tự động gợi ý danh sách khách sạn, nhà hàng và điểm tham quan phù hợp với sở thích của từng du khách trên ứng dụng du lịch.
- **Pipeline trên Databricks**:
 - *Lưu trữ (DBFS/Delta)*: Lưu trữ dữ liệu đánh giá điểm đến du lịch trên DBFS.
 - *Xử lý (PySpark & SQL)*: Xây dựng ma trận tương tác Du khách - Địa điểm du lịch bằng Spark SQL.
 - *AI/MLlib (Spark ML)*: Sử dụng mô hình lọc cộng tác **ALS (Spark MLlib)** để tạo danh sách Top-10 địa điểm du lịch cho người dùng.
 - *Giá trị quản trị*: Tăng mức độ gắn kết của người dùng trên ứng dụng và kích cầu dịch vụ du lịch địa phương.
- **Dataset đề xuất**: *TripAdvisor Travel Reviews / Yelp Dataset*.

4.5.4 Đề tài 24: Dự Báo Nhu Cầu Đặt Món Trên Nền Tảng Food Delivery (Food Demand Forecasting)

- **Bài toán kinh doanh**: Dự báo số lượng suất ăn cần chuẩn bị trong các khung giờ cao điểm để nhà hàng chuẩn bị nguyên liệu tươi sống, tránh lãng phí.
- **Pipeline trên Databricks**:
 - *Lưu trữ (DBFS/Delta)*: Lưu trữ lịch sử order món ăn theo từng khung giờ trên Delta Lake.
 - *Xử lý (PySpark & SQL)*: Dùng PySpark tính các chỉ số: yếu tố thời tiết, ngày trong tuần, chương trình khuyến mãi.
 - *AI/MLlib (Spark ML)*: Hồi quy dự báo số lượng order bằng **Linear Regression / Random Forest Regressor**.
 - *Giá trị quản trị*: Giảm 30% tỷ lệ hư hao thực phẩm và chuẩn bị đủ shipper trong khung giờ cao điểm.
- **Dataset đề xuất**: *Food Delivery Demand Forecasting (Kaggle)*.

4.5.5 Đề tài 25: Phân Khúc Trải Nghiệm Du Khách Dựa Trên Đánh Giá Dịch Vụ (Tourist Segmentation by Reviews)

- **Bài toán kinh doanh**: Phân loại du khách thành các nhóm: *Du lịch nghỉ dưỡng cao cấp, Du lịch phượt trải nghiệm, Du lịch công tác, Du lịch gia đình* để xây dựng combo tour phù hợp.
- **Pipeline trên Databricks**:
 - *Lưu trữ (DBFS/Delta)*: Nạp dữ liệu đánh giá văn bản và mức chi tiêu vào DBFS.
 - *Xử lý (PySpark & SQL)*: Trích xuất đặc trưng văn bản và chỉ số chi tiêu với PySpark Feature Transformers.
 - *AI/MLlib (Spark ML)*: Gom cụm bằng **K-Means Clustering** trên Spark MLlib.
 - *Giá trị quản trị*: Thiết kế các gói tour du lịch nhắm trúng thị hiếu của từng phân khúc khách hàng.
- **Dataset đề xuất**: *TripAdvisor Hotel Reviews Dataset*.

4.6 Lĩnh Vực 6: Y Tế, Nhân Sự & Quản Trị Vận Hành (Healthcare & Operations)

4.6.1 Đề tài 26: Dự Báo Chi Phí Bảo Hiểm Y Tế Cá Nhân (Health Insurance Cost Prediction)

- **Bài toán kinh doanh:** Giúp công ty bảo hiểm tính toán phí bảo hiểm (Insurance Premium) chuẩn xác cho từng khách hàng dựa trên các yếu tố rủi ro sức khỏe.
- **Pipeline trên Databricks:**
 - *Lưu trữ (DBFS/Delta):* Lưu trữ hồ sơ bảo hiểm ẩn danh trên Delta Lake.
 - *Xử lý (PySpark & SQL):* Làm sạch dữ liệu, tính chỉ số khối cơ thể (BMI), mã hóa thói quen hút thuốc và vùng miền.
 - *AI/MLlib (Spark ML):* Huấn luyện mô hình hồi quy đa biến **Linear Regression** / **GBTRegressor** dự báo **charges**.
 - *Giá trị quản trị:* Xây dựng bảng phí bảo hiểm công bằng, minh bạch và đảm bảo biên lợi nhuận an toàn.
- **Dataset đề xuất:** *Medical Cost Personal Datasets (Kaggle).*

4.6.2 Đề tài 27: Dự Báo Nhân Viên Nghỉ Việc (HR Employee Attrition Prediction)

- **Bài toán kinh doanh:** Giúp phòng nhân sự (HR) phát hiện sớm nhân sự chủ chốt có ý định nhảy việc để có chính sách đãi ngộ, thăng tiến giữ chân nhân tài.
- **Pipeline trên Databricks:**
 - *Lưu trữ (DBFS/Delta):* Lưu trữ bảng dữ liệu nhân sự (mức lương, số năm kinh nghiệm, đánh giá hiệu suất, số giờ làm thêm) trên DBFS.
 - *Xử lý (PySpark & SQL):* Phân tích tương quan giữa mức độ hài lòng với công việc và tỷ lệ thôi việc.
 - *AI/MLlib (Spark ML):* Xây dựng Pipeline phân loại nhị phân **Decision Tree** / **Random Forest Classifier**.
 - *Giá trị quản trị:* Phòng vãn giữ chân kịp thời đối với nhân sự có nguy cơ thôi việc cao, giảm chi phí tuyển dụng thay thế.
- **Dataset đề xuất:** *IBM HR Analytics Employee Attrition & Performance.*

4.6.3 Đề tài 28: Dự Báo Khả Năng Tái Nhập Viện Của Bệnh Nhân (Hospital Readmission Prediction)

- **Bài toán kinh doanh:** Giúp các bệnh viện tư nhân tối ưu hóa phác đồ điều trị, giảm chi phí phạt bảo hiểm do bệnh nhân tái nhập viện trong vòng 30 ngày.
- **Pipeline trên Databricks:**
 - *Lưu trữ (DBFS/Delta):* Nạp dữ liệu bệnh án điện tử (EHR) vào Delta Table.
 - *Xử lý (PySpark & SQL):* Dùng Spark DataFrame tổng hợp số ngày nằm viện, số lượng thuốc sử dụng và kết quả xét nghiệm.
 - *AI/MLlib (Spark ML):* Phân loại nhị phân bằng **Logistic Regression** / **GBTClassifier** để phân tầng nhóm bệnh nhân nguy cơ cao.
 - *Giá trị quản trị:* Thiết lập quy trình chăm sóc hậu xuất viện (Follow-up Call) cho bệnh nhân có nguy cơ cao.
- **Dataset đề xuất:** *Diabetes 130-US hospitals for years 1999-2008 Dataset (UCI).*

4.6.4 Đề tài 29: Dự Báo Mức Tiêu Thụ Điện Năng Cho Nhà Máy Sản Xuất (Industrial Energy Consumption Forecasting)

- **Bài toán kinh doanh:** Giúp giám đốc vận hành nhà máy dự báo công suất tiêu thụ điện để lên kế hoạch sản xuất vào giờ thấp điểm, tiết kiệm chi phí năng lượng.
- **Pipeline trên Databricks:**
 - *Lưu trữ (DBFS/Delta):* Nạp chuỗi thời gian tiêu thụ điện năng theo chu kỳ 15 phút vào Delta Lake.

- *Xử lý (PySpark & SQL)*: PySpark Window Functions tính công suất đỉnh (Peak Load) và phụ tải cơ sở.
- *AI/MLlib (Spark ML)*: Mô hình hồi quy **GBTR regressor** dự báo phụ tải điện ngày hôm sau.
- *Giá trị quản trị*: Lập kế hoạch vận hành dây chuyền sản xuất công suất lớn vào khung giờ giá điện thấp điểm.
- **Dataset đề xuất**: *Steel Industry Energy Consumption / Household Electric Power Consumption (UCI)*.

4.6.5 Đề tài 30: Đánh Giá Và Phân Loại Rủi Ro An Toàn Lao Động (Workplace Safety Incident Risk Assessment)

- **Bài toán kinh doanh**: Dự báo các phân xưởng có nguy cơ xảy ra tai nạn lao động cao để siết chặt quy trình bảo hộ, giảm thiểu rủi ro bồi thường và bảo vệ người lao động.
 - **Pipeline trên Databricks**:
 - *Lưu trữ (DBFS/Delta)*: Lưu log báo cáo sự cố an toàn trên DBFS.
 - *Xử lý (PySpark & SQL)*: Thống kê số giờ làm việc liên tục, nhiệt độ môi trường và thâm niên công nhân.
 - *AI/MLlib (Spark ML)*: Phân loại mức độ rủi ro (*Cao, Trung bình, Thấp*) bằng **Multiclass Random Forest (Spark MLlib)**.
 - *Giá trị quản trị*: Tăng cường tần suất kiểm tra an toàn tại các phân xưởng có điểm rủi ro cao.
 - **Dataset đề xuất**: *Industrial Safety and Health Incidents Dataset*.
-

Chương 5

Tiêu Chí Đánh Giá Tiểu Luận (Rubric)

Tiêu chí	Tỷ trọng	Yêu cầu đạt mức Tốt - Xuất sắc
1. Ý nghĩa Nghiệp vụ & Đặt vấn đề	15%	Nêu bật được bài toán kinh doanh thực tế, phân tích đầy đủ đặc tính dữ liệu lớn theo mô hình 5Vs.
2. Quản trị & Lưu trữ Dữ liệu trên Databricks	20%	Nạp dữ liệu vào DBFS chuẩn xác; tổ chức dữ liệu theo mô hình Medallion (Bronze/Silver/Gold) dạng Delta Lake.
3. Xử lý & Phân tích Dữ liệu lớn (PySpark & SQL)	25%	Sử dụng thành thạo PySpark DataFrame & Spark SQL; thực hiện làm sạch dữ liệu, xử lý thiếu, Feature Engineering tối ưu.
4. Mô hình hóa AI (Spark MLlib Pipeline)	25%	Xây dựng hoàn chỉnh Machine Learning Pipeline; tinh chỉnh siêu tham số bằng CrossValidator; đánh giá mô hình đa chỉ số (AUC, F1, RMSE).
5. Báo cáo & Khuyến nghị Kinh doanh	15%	Báo cáo trình bày mạch lạc, trực quan hóa biểu đồ rõ ràng trên Databricks; đưa ra đề xuất giá trị thực tế cho doanh nghiệp.